LAPORAN PRAKTIKUM 3
Classification dengan Ensemble Method & Class Imbalance

Mata Kuliah : Penambangan Data

Dataset : **Credit Card Fraud Detection**

Disusun Oleh :

Muhammad Fasya Atthaya Rosyada

5054251006

Program Studi Rekayasa Kecerdasan Artifisial

Institut Teknologi Sepuluh Nopember

2026

1 Pendahuluan

Klasifikasi pada dataset dunia nyata sering kali dihadapkan pada masalah ketidakseimbangan kelas (*class imbalance*), di mana jumlah sampel pada satu kelas jauh melampaui kelas lainnya. Jika tidak ditangani, model *machine learning* akan cenderung bias dalam memprediksi kelas mayoritas.

Tujuan praktikum ini adalah membangun model klasifikasi menggunakan *ensemble method* (Random Forest) pada dataset Credit Card Fraud Detection, serta menerapkan teknik *oversampling* (SMOTE) untuk mengatasi ketidakseimbangan kelas. Dataset ini berisi data transaksi kartu kredit dengan total 284.807 baris dan 31 kolom, di mana target klasifikasinya adalah mendeteksi transaksi normal (0) dan transaksi penipuan/fraud (1).

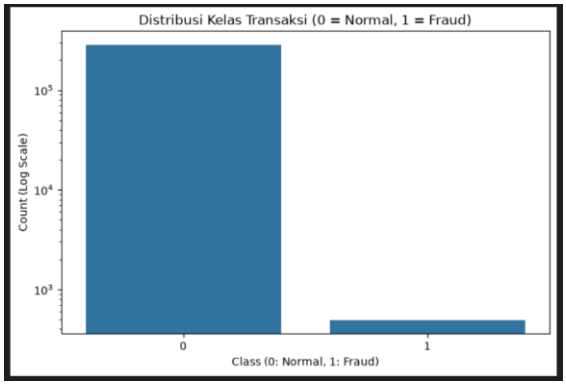
2 Exploratory Data Analysis (EDA)

Sebelum melakukan pemodelan, eksplorasi awal dilakukan untuk memahami struktur data dan tingkat ketidakseimbangan kelas pada target prediksi.

2.1 Struktur Dataset dan Statistik Deskriptif

Dataset awal terdiri dari 284.807 sampel dan 31 atribut, yang semuanya merupakan fitur numerik. Fitur V1 hingga V28 merupakan hasil transformasi *Principal Component Analysis* (PCA) untuk menjaga kerahasiaan data pengguna, sedangkan fitur Time dan Amount tidak diubah. Tidak ditemukan *missing value* dalam dataset ini, namun terdapat 1.081 baris data duplikat yang perlu ditangani.

2.2 Analisis Variabel Target



Berdasarkan eksplorasi pada variabel target Class, ditemukan ketimpangan ekstrem pada distribusi data:

- **Kelas 0 (Normal):** 284.315 transaksi (99,827%)
- **Kelas 1 (Fraud):** 492 transaksi (0,173%)

Ketimpangan ini menunjukkan bahwa observasi transaksi penipuan sangat jarang terjadi dibandingkan dengan transaksi normal.

3 Pembersihan dan Praproses Data

3.1 Penanganan Data Duplikat

Meskipun tidak ada *missing values*, dataset memiliki 1.081 observasi yang merupakan duplikat. Seluruh duplikat ini dihapus untuk mencegah model mengalami *overfitting* dan memberikan bobot berlebih pada data berulang, sehingga ukuran dataset menyusut menjadi 283.726 baris.

3.2 Data Splitting

Dataset dibagi menjadi data latih (80%) dan data uji (20%). Agar proporsi transaksi *fraud* yang sangat sedikit tetap terdistribusi secara merata di kedua set, digunakan parameter stratify=y pada proses pembagian data.

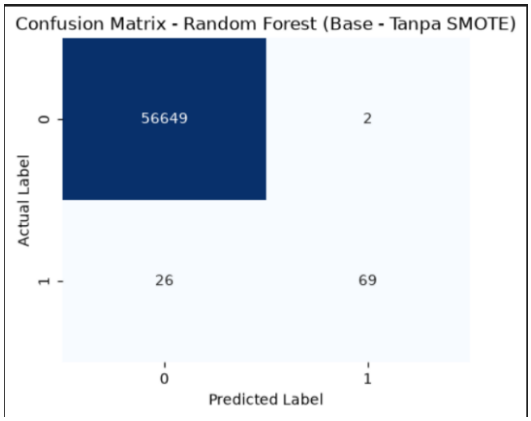
4 Penanganan Class Imbalanced

Untuk menangani masalah *class imbalance*, pendekatan yang digunakan adalah **Oversampling menggunakan metode SMOTE (Synthetic Minority Over-sampling Technique)**. Penerapan *resampling* ini dilakukan secara ketat **hanya pada data latih (training data)** agar kebocoran data (*data leakage*) dapat dicegah. Data uji dibiarkan pada distribusi aslinya untuk menguji model pada skenario dunia nyata yang memang tidak seimbang. Setelah SMOTE diterapkan, jumlah sampel kelas minoritas (1) di data latih disintesis sedemikian rupa sehingga seimbang 50:50 dengan kelas mayoritas (0).

5 Membangun Model Klasifikasi & Evaluasi

Model dibangun menggunakan metode *ensemble* yaitu Random Forest. Pengujian dilakukan dalam dua skenario untuk melihat dampak penanganan *imbalance*:

5.1 Model Random Forest (Base - Tanpa SMOTE)




```
========== Evaluasi Random Forest (Base - Tanpa SMOTE) ==========
Classification Report:
              precision    recall  f1-score   support

           0       1.00      1.00      1.00     56651
           1       0.97      0.73      0.83        95

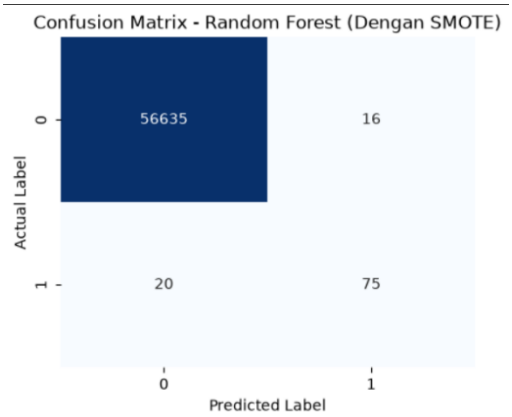
    accuracy                           1.00     56746
   macro avg       0.99      0.86      0.92     56746
weighted avg       1.00      1.00      1.00     56746

AUC-ROC Score: 0.9239
```

Pada model *baseline* tanpa penanganan *imbalance*, model sangat baik memprediksi kelas mayoritas, tetapi kurang optimal pada kelas minoritas:

- **Recall (Fraud):** 0,73
- **Precision (Fraud):** 0,97
- **F1-Score (Fraud):** 0,83
- **AUC-ROC Score:** 0,9239
- **Analisis Confusion Matrix:** Terdapat 69 kasus True Positives, namun model gagal mendeteksi 26 transaksi penipuan (False Negatives).

5.2 Model Random Forest (Dengan SMOTE)




```
========== Evaluasi Random Forest (Dengan SMOTE) ==========
Classification Report:
              precision    recall  f1-score   support

           0       1.00      1.00      1.00     56651
           1       0.82      0.79      0.81        95

    accuracy                           1.00     56746
   macro avg       0.91      0.89      0.90     56746
weighted avg       1.00      1.00      1.00     56746

AUC-ROC Score: 0.9727
```

Setelah model dilatih menggunakan data hasil SMOTE, sensitivitas model meningkat:

- **Recall (Fraud):** 0,79
- **Precision (Fraud):** 0,82
- **F1-Score (Fraud):** 0,81
- **AUC-ROC Score:** 0,9727
- **Analisis Confusion Matrix:** Kemampuan mendeteksi penipuan meningkat menjadi 75 True Positives, dan False Negatives berhasil ditekan menjadi 20 kasus. Walaupun *False Positives* sedikit meningkat (16 kasus), hal ini adalah *trade-off* yang wajar.

6 Ringkasan Akhir dan Analisis Metrik

Dalam permasalahan deteksi *fraud* dengan *imbalanced dataset*, akurasi (*accuracy*) bukanlah metrik yang valid. Sebuah model yang selalu menebak "Normal" akan tetap mendapatkan akurasi di atas 99,8% karena dominasi kelas 0, namun model tersebut tidak berguna secara praktis.

Kerugian finansial dari satu kasus penipuan yang lolos (False Negative) jauh lebih masif dibandingkan biaya memverifikasi peringatan palsu (False Positive). Oleh karena itu, penerapan SMOTE terbukti sangat efektif karena berhasil meningkatkan metrik **Recall** dan skor **AUC-ROC** secara signifikan. Model menjadi lebih agresif dan sensitif dalam menangkap pola penipuan kartu kredit yang sesungguhnya.