

# LAPORAN PRAKTIKUM 2

## PRAPROSES DATA

Mata Kuliah : Penambangan Data

Dataset : **House Prices – Advances Regression Techniques**

Disusun Oleh :

Muhammad Fasya Atthaya Rosyada

5054251006

Program Studi Rekayasa Kecerdasan Artifisial

Institut Teknologi Sepuluh Nopember

2026

# 1 Pendahuluan

Praproses data (data preprocessing) adalah tahapan yang krusial dalam siklus machine learning. Data mentah di dunia nyata sering kali mengandung missing values, nilai pencilan (outliers), inkonsistensi tipe data, serta dimensi fitur yang sangat tinggi.

Tujuan praktikum ini adalah untuk merekayasa dataset train.csv (1.460 baris, 81 kolom) agar menjadi dataset yang bersih, terstandardisasi, dan siap digunakan untuk pemodelan regresi prediksi harga rumah

## 2 Exploratory Data Analysis (EDA)


Sebelum melakukan tindakan praproses data, eksplorasi awal harus dilakukan terlebih dahulu untuk memahami struktur dan distribusi data secara mendalam.

### 2.1 Struktur Dataset dan Statistik Deskriptif

Dataset awal terdiri dari **1.460 sampel** dan **81 atribut**, yang terbagi menjadi:


- **Fitur Numerik** : 38 atribut (termasuk Id dan variabel target SalePrice).
- **Fitur Kategorikal** : 43 atribut (tipe data object/string).

### 2.2 Analisis Variabel Target



Visualisasi grafik distribusi menunjukkan bahwa atribut target SalePrice memiliki bentuk distribusi right-skewed (miring ke kanan). Hal ini mengindikasikan sebagian besar rumah berada pada rentang harga menengah (sekitar \$100.000 – \$250.000), sedangkan sebagian kecil rumah memiliki harga sangat tinggi.

## 2.3 Analisis Korelasi Fitur Terhadap Target




Berdasarkan analisis korelasi Pearson, fitur-fitur numerik yang memiliki pengaruh paling signifikan terhadap variabel target SalePrice adalah:

1. **OverallQual** ( $r = 0,79$ ) - Kualitas material dan penyelesaian rumah.
2. **GrLivArea** ( $r = 0,71$ ) - Luas ruang tamu di atas permukaan tanah.
3. **GarageCars** ( $r = 0,64$ ) & **GarageArea** ( $r = 0,62$ ) - Kapasitas dan luas garasi.
4. **TotalBsmtSF** ( $r = 0,61$ ) & **1stFlrSF** ( $r = 0,61$ ) - Luas basement dan lantai pertama.

## 3 Pembersihan Data

### 3.1 Penanganan Missing Values



Pengecekan persentase nilai yang hilang pada setiap atribut menunjukkan beberapa fitur memiliki proporsi *missing value* di atas 50%. Pada tahap ini dilakukan beberapa proses yaitu :

### 1. Penghapusan Kolom (> 50% Missing):


Atribut Alley (93,77%), MasVnrType (59,73%), PoolQC (99,52%), Fence (80,75%), dan MiscFeature (96,30%) dihapus dari dataset sesuai dengan ketentuan. Atribut Id juga dihapus karena tidak memiliki nilai informatif.

### 2. Imputasi Nilai Hilang:

- Fitur Numerik: Diisi menggunakan median kolom, karena median tahan terhadap pengaruh pencilan/outlier.
- Fitur Kategorikal: Diisi menggunakan modus (nilai dengan frekuensi kemunculan tertinggi).

## 4 Deteksi dan Penanganan Outlier

### 4.1 Deteksi Outlier



Deteksi pencilan dilakukan menggunakan visualisasi boxplot pada variabel-variabel kontinu utama seperti GrLivArea, TotalBsmtSF, LotArea, dan 1stFlrSF. Terdeteksi beberapa sampel rumah dengan luas ekstrem yang jauh melampaui batas atas Interquartile Range (IQR).

### 4.2 Penanganan Outlier

Outlier tidak dihapus, melainkan disesuaikan nilainya menggunakan metode Capping. Alasannya adalah karena menghapus baris outlier dapat mengurangi informasi penting dari sampel rumah berukuran besar. Nilai pencilan yang melewati batas  $[Q1 - 1,5 \times IQR]$  atau  $[Q3 + 1,5 \times IQR]$  dibatasi tepat pada nilai ambang batas tersebut.

## 5 Transformasi Data

### 5.1 Encoding Atribut Kategorikal

Seluruh 38 fitur kategorikal ditransformasikan ke bentuk numerik menggunakan metode One-Hot Encoding (`pd.get_dummies` dengan `drop_first=True`). Prosedur ini mencegah terjadinya dummy variable trap.

## 5.2 Standarisasi Fitur Numerik

Fitur-fitur numerik independen di-skala menggunakan `StandardScaler` (Standardisasi Z-score). Standardisasi ini memastikan setiap variabel memiliki rerata ( $\mu = 0$ ) dan standar deviasi ( $\sigma = 1$ ), sehingga algoritma berbasis jarak/matriks dapat bekerja secara optimal.

# 6 Reduksi Dimensi

## 6.1 Analisis Korelasi

Untuk menghindari masalah multikolinearitas, dilakukan analisis korelasi antar-fitur independen. Fitur yang memiliki korelasi linear  $> 0,80$  dibuang salah satunya:

- GarageArea vs GarageCars ( $r = 0,88$ ): GarageArea dibuang karena informasinya redundan dengan GarageCars.
- TotRmsAbvGrd vs GrLivArea ( $r = 0,82$ ): TotRmsAbvGrd dibuang.
- 1stFlrSF vs TotalBsmtSF ( $r = 0,82$ ): 1stFlrSF dibuang.

## 6.2 Principal Component Analysis (PCA)

Setelah one-hot encoding, dimensi dataset membengkak menjadi puluhan/ratusan fitur. Teknik PCA diterapkan untuk memadatkan dimensi:

- Threshold Variance: Menerapkan `n_components=0.90` (mempertahankan 90% total variansi/informasi data asli).
- Hasil PCA: Dimensi berhasil diringkas menjadi komponen-komponen utama (PC\_1, PC\_2, dst.) yang bersifat saling orthogonal (tidak berkorelasi).

# 7 Ringkasan Akhir Dataset

Pada akhirnya dataset disimpan ke file “5054251006\_Fasya\_Tugas\_Praposes\_Data.csv” dengan 1460 baris dan 231 kolom termasuk target hasil dari One-Hot Encoding setelah dikurangi fitur redundan dan ID. Dataset ini telah bersih sepenuhnya dari missing values karena imputasi dan atribut numeriknya juga sudah terstandarisasi. Dataset ini hanya dataset clean sebelum dilakukan PCA.