

LAPORAN ANALISIS EKSPLORASI DATA

Dataset : Top 1550 anime by Myanimelist

1. Deskripsi Dataset

Dataset yang digunakan adalah data sekunder yang didapatkan lewat metode web scraping dari halaman "Top Anime" di situs MyAnimeList (MAL) menggunakan library request dan BeautifulSoup. Dataset ini memuat 1550 baris data anime terbaik berdasarkan rating dari para fans.

Ada 8 atribut utama yang dianalisis dalam dataset ini setelah melalui proses ekstraksi, yaitu:

1. **Title** (Kategorikal - Nominal): Judul tayangan anime.
2. **Type** (Kategorikal - Nominal): Format penayangan (contoh: TV, Movie, OVA).
3. **Aired Date** (Kategorikal - Nominal): Rentang waktu tayang dalam bentuk teks.
4. **Rank** (Numerik - Ordinal): Peringkat klasemen berdasarkan skor tertinggi.
5. **Score** (Numerik - Kontinu): Nilai rata-rata ulasan pengguna (skala 1-10).
6. **Episodes** (Numerik - Diskrit): Jumlah total episode penayangan.
7. **Members** (Numerik - Diskrit): Jumlah pengguna MAL yang menyimpan anime tersebut di daftar mereka.
8. **Release Year** (Numerik - Diskrit): Tahun rilis yang diekstrak dari atribut Aired Date.

2. Statistik Deskriptif

Berdasarkan hasil komputasi fungsi statistik dasar, ditemukan beberapa karakteristik utama dari populasi "Top Anime" ini:

- **Atribut Numerik:** Distribusi skor cenderung mengumpul di nilai tinggi, yaitu pada kisaran kuartil 7.5 hingga 8.5. Hal ini wajar karena sampel data diambil khusus dari klasemen tayangan terbaik. Rata-rata jumlah episode berada di sekitar belasan hingga puluhan episode, namun memiliki angka maksimal hingga ratusan episode.
- **Atribut Kategorikal:** Tipe tayangan sangat didominasi oleh format **TV**, disusul oleh format **Movie** dan **OVA**. Dilihat dari tahun rilisnya, anime yang masuk dalam peringkat atas lebih banyak berasal dari era modern. Mayoritas anime dengan peringkat terbaik dirilis setelah tahun 2010.

3. Penanganan Data

Dataset mentah hasil scraping HTML diproses melalui tahap data cleaning untuk mendukung perhitungan matematis.

- **Pembersihan Teks:** Menghilangkan tanda koma (,) dan teks tambahan (seperti kata "members" dan "eps") agar atribut dapat dikonversi menjadi tipe data numerik (Integer dan

Float). Atribut Aired Date juga diekstrak menggunakan RegEx untuk mengambil 4 digit tahun rilisnya.

- **Penanganan Missing Value:** Terdapat nilai kosong pada atribut Episodes karena tayangan masih berstatus on-going sehingga jumlah episodenya "?". Nilai ini dipaksa berubah menjadi representasi NaN (Not a Number) menggunakan argumen `errors='coerce'`. Nilai NaN ini **tidak dihapus** dari dataset agar tidak menghilangkan informasi penting di atribut lain (seperti Score dan Title).
- **Penanganan Outlier :** Deteksi outlier dilakukan menggunakan metode Interquartile Range (IQR). Ditemukan banyak outliers pada atribut Episodes (tayangan dengan ratusan episode) dan Members (popularitas jutaan pengguna). Outliers ini dibiarkan karena merupakan data anomali yang valid dan nyata dan bukan karena kesalahan input sistem.

4. Visualisasi & Interpretasi

Dalam analisis bivariat dan multivariat, enam grafik telah dibuat untuk mencari korelasi antar atribut:

1. **Scatter Plot (Members vs Score):** Terdapat korelasi linier positif yang kuat. Tayangan dengan skor penilaian tertinggi (di atas 8.5) berbanding lurus dengan popularitasnya, dibuktikan dengan member yang masif.
2. **Boxplot (Skor berdasarkan Tipe):** Meskipun format seri TV memiliki kuantitas terbanyak, nilai median skor format Movie terbukti bersaing sangat ketat. Hal ini menunjukkan tayangan tipe movie rata-rata memiliki standar penyutradaraan dan kualitas yang lebih terjaga.
3. **Boxplot (Episode berdasarkan Tipe):** Format Movie dan OVA memiliki rentang penyebaran episode yang sempit dimana median mendekati angka 1, sementara format TV sangat lebar dan terpusat di standar musim 12-24 episode per tayangan.
4. **Scatter Plot (Episode vs Score):** Plot sebaran membuktikan tidak adanya hubungan matematis antara panjang durasi seri dan tingginya skor. Anime dengan ratusan episode tidak menjamin rating yang lebih baik dibandingkan anime standar satu season yaitu 12-24 episode.
5. **Regresi Tren (Tahun Rilis vs Score):** Garis regresi menunjukkan pola yang nyaris stabil melintasi waktu. Ini membuktikan tidak ada perbedaan standar penilaian antara anime jadul dengan anime modern.
6. **Heatmap Korelasi:** Memvalidasi seluruh temuan grafis menggunakan matriks pearson. Rank dan Score berkorelasi negatif kuat (-1), Members dan Score berkorelasi positif. Sementara itu, Episodes tidak memiliki angka korelasi yang signifikan terhadap perolehan skor akhir.